Attention Is All You Need

Attention Is All You Need

2024

Attention Is All You Need

- Transformer: 完全基于注意力机制的新型网络架构
- Ashish Vaswani, Noam Shazeer, Niki Parmar 等 Google 团队
- NeurIPS 2017 (2017 年 12 月)
- 首次提出摒弃 RNN 和卷积，仅使用注意力机制进行序列建模
- 开创了深度学习自然语言处理的新时代

研究背景与动机

- RNN、LSTM 和 GRU 是序列建模的主流方法
- RNN 的顺序计算特性限制了并行化能力
- 序列越长，内存约束越严重，批处理困难
- 注意力机制可建模任意距离的依赖关系
- 现有模型将注意力与 RNN 结合，非纯注意力架构

相关工作

- ByteNet 和 ConvS2S 使用卷积实现并行计算
- 但连接任意位置的操作数随距离线性或对数增长
- Self-attention 已用于阅读理解、摘要等任务
- 端到端记忆网络基于注意力而非时序循环
- Transformer 是首个完全基于自注意力的模型

Transformer 架构概览

- 采用标准的 Encoder-Decoder 结构
- 完全基于注意力机制，摒弃循环和卷积
- 堆叠 6 层相同的 Encoder 和 Decoder 模块
- 每个子层使用残差连接和层归一化
- 所有子层输出维度 dmodel = 512

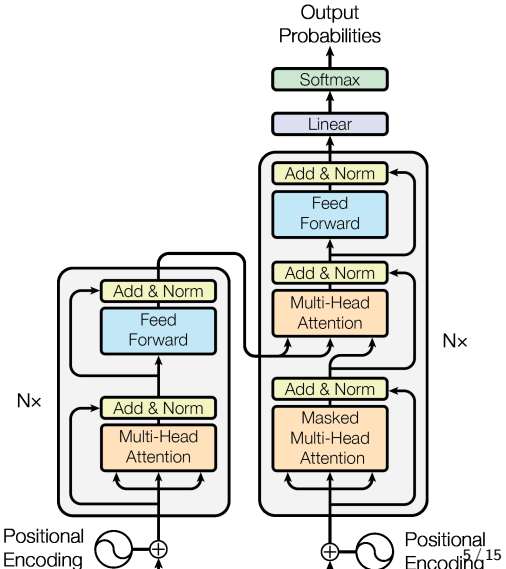

注意力机制：Scaled Dot-Product Attention

- 输入：Query Q, Key K, Value V 三个向量
- 计算 Q 与所有 K 的点积，除以 $\sqrt{dk}$ 进行缩放
- 应用 softmax 获得注意力权重
- 公式：$\text{Attention}(Q,K,V) = \text{softmax}(QKT/\sqrt{dk})V$
- 缩放因子防止点积过大导致梯度消失

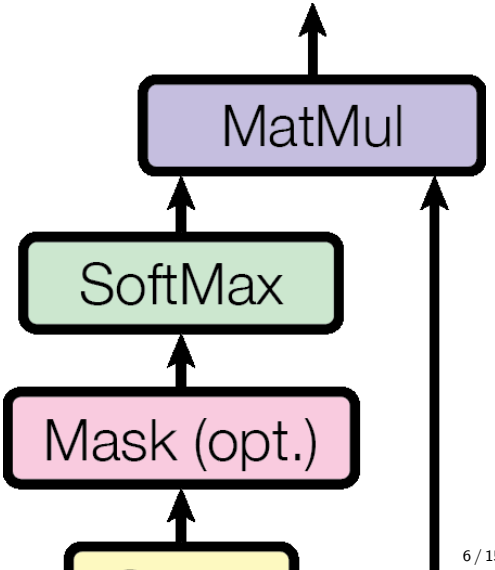

多头注意力机制 (Multi-Head Attention)

- 将 Q、K、V 投影到 h 个不同的子空间（h=8）
- 每个头维度 dk = dv = dmodel/h = 64
- 并行计算各头的注意力后拼接
- 公式：MultiHead(Q,K,V) = Concat(head1,...,headh)WO
- 多头机制允许同时关注不同表示子空间的信息

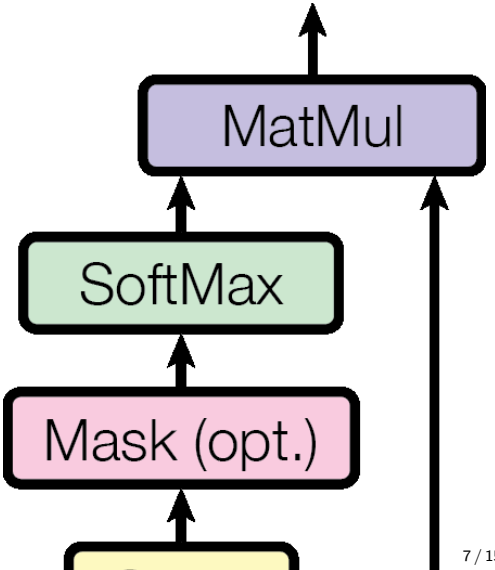

Transformer 中的三种注意力应用

- Encoder Self-Attention：所有 K、V、Q 来自同一位置
- Decoder Self-Attention：防止看向后续位置（Masking）
- Encoder-Decoder Attention：Q 来自 Decoder，K、V 来自 Encoder
- Decoder 采用 Masked Attention 确保自回归特性
- 实现了输入输出序列的全局依赖建模

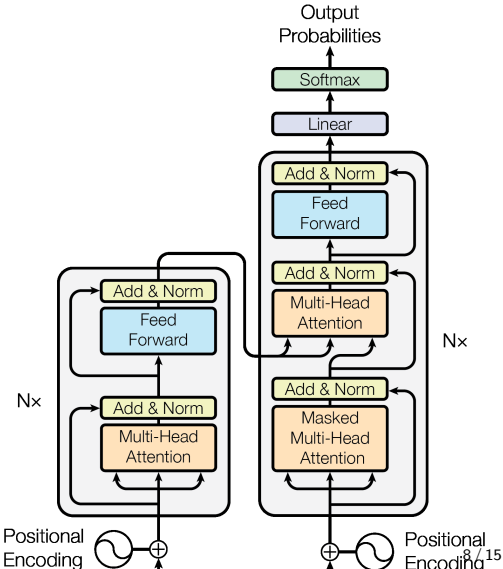

位置编码与前馈网络

- 使用正弦/余弦函数生成位置编码
- PE(pos,2i) = sin(pos/100002i/dmodel)
- PE(pos,2i+1) = cos(pos/100002i/dmodel)
- 前馈网络：FFN(x) = max(0, xW1+b1)W2+b2
- 位置编码维度与词嵌入相同，可直接相加

实验设置

- WMT 2014 English-German: 约 450 万句子对
- WMT 2014 English-French: 3600 万句子对
- 使用 Byte-pair Encoding (BPE) 进行分词
- 训练硬件：8 块 NVIDIA P100 GPU
- 基础模型训练 12 小时，大模型训练 3.5 天

机器翻译实验结果

- English-German: 28.4 BLEU (state-of-the-art)
- English-French: 41.8 BLEU (state-of-the-art)
- 比此前最佳模型提升超过 2 BLEU
- 训练成本仅为最佳模型的 1/4
- 基础模型也超越所有此前发布的单模型

模型变种与消融分析

- 多头注意力中，头数过多或过少都会降低性能
- 减小 attention key 维度会损害模型质量
- 更大的模型和适当的 dropout 有助于性能提升
- 位置编码：正弦编码与学习编码效果相当
- 模型深度增加显著提升 BLEU 分数

泛化能力：英文 constituency 解析

- 仅用 WSJ 数据集 (40K 句子) 训练即可超越 Berkeley Parser
- 半监督设置下达到 92.7 F1 分数
- 证明 Transformer 具有强大的任务泛化能力
- 输出结构化结果，无需任务特定的调参
- 验证了模型对长距离依赖的有效建模

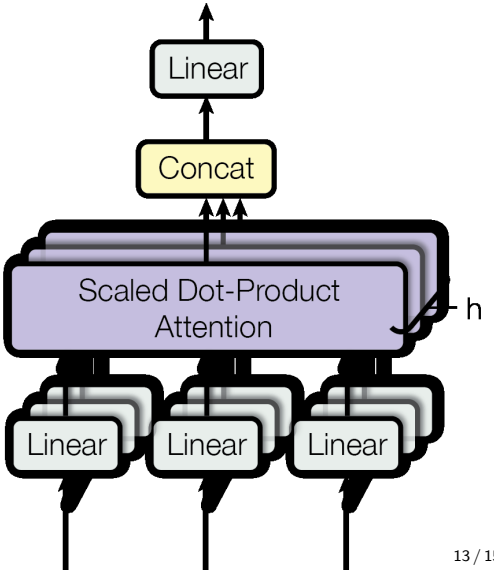

总结与展望

- Transformer 是完全基于注意力机制的序列转导模型
- 可并行化训练，显著缩短训练时间
- 在翻译任务上达到新的最佳性能
- 未来方向：处理图像、音频等非文本模态
- 探索局部注意力机制以处理更长序列

关键参考文献

2 Bahdanau et al., Neural Machine Translation by Jointly Learning to Align and Translate, 2014

9 Gehring et al., Convolutional Sequence to Sequence Learning, 2017

18 Kalchbrenner et al., Neural Machine Translation in Linear Time, 2017

35 Sutskever et al., Sequence to Sequence Learning with Neural Networks, 2014

38 Wu et al., Google's Neural Machine Translation System, 2016