Attention Is All You Need

Attention Is All You Need

2024

Attention Is All You Need

- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit 等
- Google Brain & Google Research
- 31st Conference on Neural Information Processing Systems (NIPS 2017)
- arXiv:1706.03762

研究背景与动机

- RNN、LSTM、GRU 是序列建模和 transduction 任务的主流方法
- RNN 的顺序计算特性限制了并行化，在长序列上内存约束明显
- 现有模型通过注意力机制连接 encoder 和 decoder
- 核心问题：能否用纯注意力机制替代 RNN/卷积?

相关工作

- Neural GPU、ByteNet、ConvS2S 使用卷积作为基本构建块
- 卷积模型中两位置间操作数随距离线性或对数增长
- Self-attention 已在阅读理解、摘要、文本蕴含等任务中成功应用
- 本文首次完全基于 self-attention 实现序列 transduction 模型

Transformer 模型架构

- 采用标准的 Encoder-Decoder 结构
- Encoder：将输入序列 (x1,...,xn) 映射为连续表示 z=(z1,...,zn)
- Decoder：自回归生成输出序列 (y1,...,ym)
- 完全基于堆叠的 self-attention 和逐位置全连接层

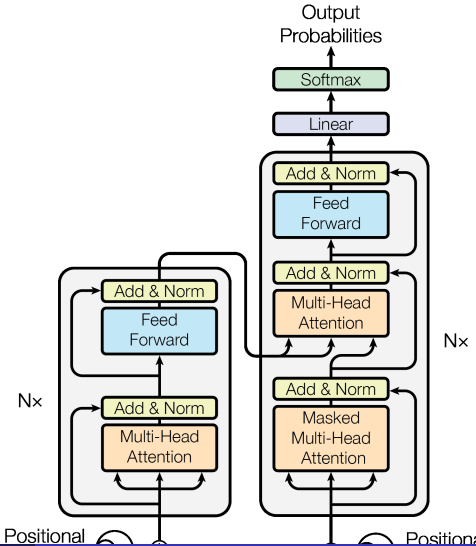

注意力机制 - Scaled Dot-Product Attention

- 输入：queries Q、keys K（维度 dk）、values V（维度 dv）
- 计算：Attention(Q,K,V) = softmax(QK^T/√dk)V
- 比加性注意力更快、更节省空间，可高度并行化
- 除以 √dk 防止点积过大导致 softmax 梯度消失

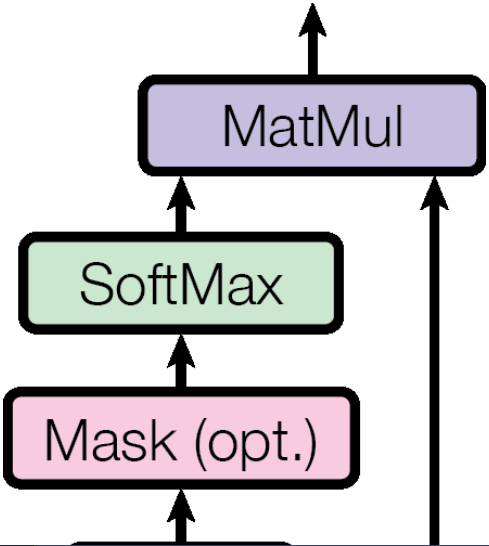

注意力机制 - Multi-Head Attention

- 将 Q、K、V 投影 h 次到不同子空间（dk=dv=dmodel/h=64）
- MultiHead(Q,K,V) = Concat(head1,...,headh)W^O
- 允许模型同时关注不同表示子空间的信息
- 总计算成本与单头注意力相近，但效果显著提升

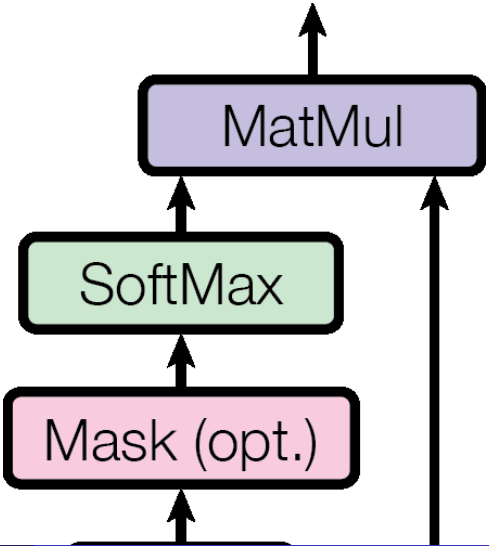

位置编码与前馈网络

- 使用正弦/余弦函数生成位置编码，与嵌入向量相加
- PE(pos,2i) = sin(pos/10000^(2i/dmodel))
- 前馈网络：FFN(x) = max(0, xW1+b1)W2+b2
- 两层线性变换，内层维度 dff=2048，激活函数 ReLU

机器翻译实验结果

- WMT 2014 英德翻译：28.4 BLEU（最佳模型），超越所有集成模型 2+ BLEU
- WMT 2014 英法翻译：41.8 BLEU（新 SOTA），训练仅需 3.5 天/8 GPU
- 比现有最佳模型的训练成本低数倍
- 基础模型：100K 步训练 12 小时；大模型：300K 步训练 3.5 天

性能对比分析

- 英德翻译：Transformer(big) 28.4 vs 之前最佳 26.3 (GNMT+RL Ensemble)
- 英法翻译：Transformer(big) 41.8 vs 之前最佳 41.29 (ConvS2S Ensemble)
- 训练 FLOPs 显著降低：英德 2.3×10^19 vs GNMT 的 1.4×10^20
- 验证了 Transformer 的高效性和优越性

注意力可视化分析

- 注意力头能学习捕捉长距离依赖关系
- 图 3：编码器第 5 层注意力准确关联'making' 与'more difficult'
- 图 4：部分注意力头专门处理回指解析（如'the Law' 与'its application'）
- 证明模型学习到了句子的句法和语义结构

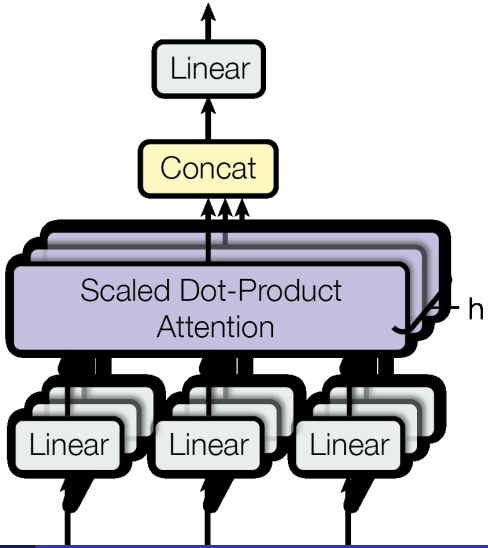

模型变体与消融实验

- (A) 头数和维度：8 头、dk=dv=64 为最佳，单头或多头过多均下降
- (B) 键维度：减小 dk 会损害模型质量，点积兼容性函数不可简化
- (C) 层数和大模型：大模型明显更优（dmodel=1024, dff=4096）
- (D) Dropout：Pdrop=0.1 有效防止过拟合；(E) 位置编码：正弦与学习版效果相当

泛化能力：成分句法分析

- 在英语成分句法分析任务上验证 Transformer 的泛化能力
- WSJ only 设置：4 层 Transformer 达到 91.3 F1，超越 BerkeleyParser
- 半监督设置（17M 句子）：92.7 F1，接近最佳 RNN Grammar 模型
- 证明模型无需任务特定调优即可很好地迁移到其他 NLP 任务

总结与展望

- Transformer 是完全基于注意力机制的新架构，摒弃了 RNN 和卷积
- 在翻译任务上训练更快、质量更好，达到新的 SOTA
- 证明了纯注意力模型的有效性和巨大潜力
- 未来方向：扩展到图像/音频/视频等模态，研究局部受限注意力

参考文献

2 Bahdanau et al. Neural machine translation by jointly learning to align and translate. CoRR, 2014

9 Gehring et al. Convolutional sequence to sequence learning. arXiv, 2017

13 Hochreiter & Schmidhuber. Long short-term memory. Neural computation, 1997

35 Sutskever et al. Sequence to sequence learning with neural networks. NIPS, 2014

38 Wu et al. Google's neural machine translation system. arXiv, 2016