深度学习笔记

Attention Is All You Need

Attention Is All You Need

目录

学习笔记: Attention Is All You Need

---

1. 研究背景与问题定义

1.1 领域背景与既有问题

在自然语言处理（NLP）和序列到序列（Sequence-to-Sequence）建模领域，**循环神经网络（RNN）**及其变体——尤其是**长短期记忆网络（LSTM）**和**门控循环单元（GRU）**——长期以来占据着主导地位。这些模型在机器翻译、语音识别、文本生成等任务中取得了显著成效。

然而，**循环模型存在根本性的计算限制**：

- **顺序计算的瓶颈**：RNN 的隐藏状态 h_t 必须按顺序依次计算（$h_t = f(h_{t-1}, x_t)$），这意味着无法在训练样本内部进行并行化处理。
- **长距离依赖问题**：尽管 LSTM 和 GRU 通过门控机制部分缓解了梯度消失问题，但学习序列中相距较远位置之间的依赖关系仍然困难。
- **内存约束**：由于需要维护完整的隐藏状态序列，内存限制严重制约了跨样本的批处理能力。

1.2 本文要解决的核心问题

本文旨在**完全消除循环连接和卷积操作**，仅依靠**注意力机制（Attention Mechanism）**来构建序列转导模型，从而：

1. **实现高度并行化**：打破顺序计算的桎梏
2. **缩短路径长度**：使任意两个位置之间的信息传递路径长度为常数 $O(1)$
3. **提升训练效率**：在更短时间内达到更好的模型质量

1.3 问题的重要性

这篇文章的重要性体现在以下几个方面：

- **范式转变**：首次证明仅靠注意力机制就能构建强大的序列到序列模型
- **实际价值**：在翻译任务上以极低的计算成本达到新的最优性能
- **深远影响**：Transformer 架构成为后续几乎所有大型语言模型（如 BERT、GPT 系列）的基础

---

2. 相关工作梳理

2.1 既有工作的回顾

工作类型	代表模型	主要贡献
循环架构	LSTM/GRU	通过门控机制捕捉长距离依赖
注意力机制	Bahdanau Attention	首次将注意力用于机器翻译的对齐
卷积架构	ByteNet, ConvS2S	并行计算，但路径长度随距离增长
记忆网络	End-to-End Memory Networks	基于注意力的记忆机制

2.2 既有工作的局限性

- **RNN 及其变体**：顺序计算本质限制了并行化和长序列处理能力
- **卷积模型**（ByteNet，ConvS2S）：虽然支持并行，但连接任意两个位置需要 $O(\log_k(n))$（ByteNet）或 $O(n/k)$（ConvS2S）层堆叠
- **混合模型**：即使加入注意力机制，仍依赖 RNN 进行序列建模

2.3 本文与既有工作的区别

特性	传统方法	Transformer
序列建模方式	循环	自注意力
路径长度	$O(n)$（RNN）或 $O(\log_k(n))$（CNN）	$O(1)$
并行化能力	有限	高度并行
计算复杂度	$O(n \cdot d^2)$	$O(n^2 \cdot d)$

Transformer 是首个完全基于自注意力、摒弃序列对齐循环的转导模型。

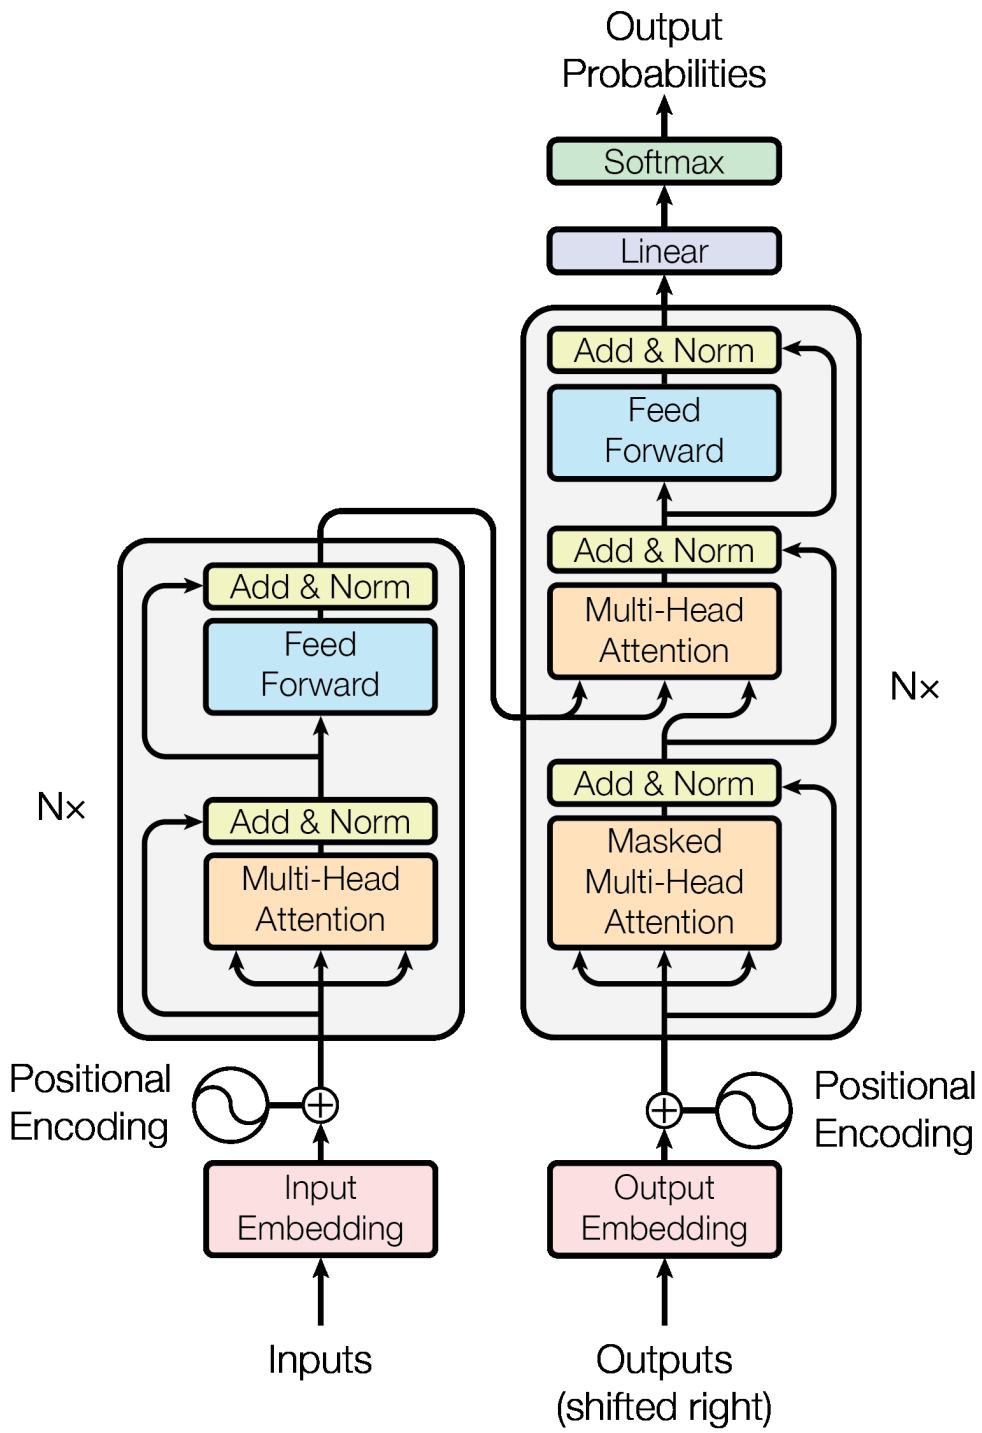
Output
Probabilities
Softmax
Linear
Add & Norm
Feed
Forward
Add & Norm
Multi-Head
Attention
Add & Norm
Masked
Multi-Head
Attention
Nx
Add & Norm
Feed
Forward
Add & Norm
Multi-Head
Attention
Nx
Positional
Encoding
Positional
Encoding
Input
Embedding
Output
Embedding
Inputs
Outputs
(shifted right)

3. 核心方法详解

3.1 整体架构概述

Transformer 采用经典的 **Encoder-Decoder** 结构，但完全基于**自注意力机制**和**位置前馈网络**构建。

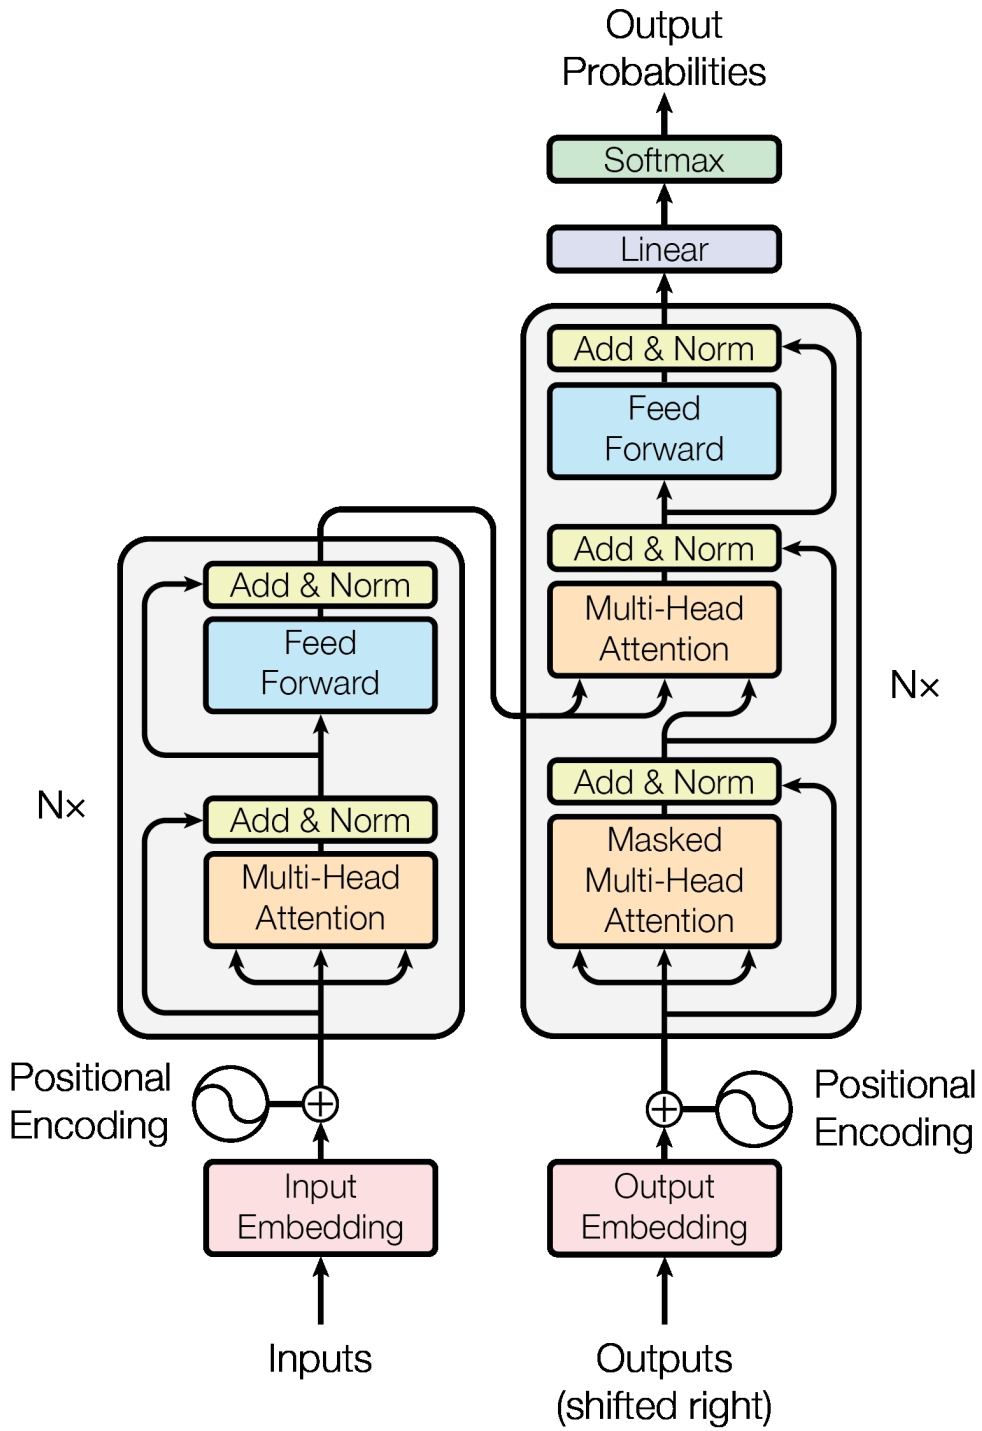

TRANSFORMER

```
Input
Tokens → Embed →
                  Encoder (×6)     → Encoder Output

                    Multi-Head
                    Self-Attention
                        +
                    Feed-Forward

                            ↓

                Decoder (×6)

            Masked Multi-Head
            Self-Attention
                 +
            Encoder-Decoder              → Output
            Multi-Head Attention             Probabilities
                 +
            Feed-Forward
```

3.2 Encoder 详解

Encoder 由 **N = 6 个相同的层**堆叠而成，每层包含两个子层：

3.2.1 多头自注意力机制（Multi-Head Self-Attention） **设计动机**：允许模型同时关注来自不同表示子空间和不同位置的信息。

工作原理：

1. 将输入分别线性投影到 h 个不同的子空间（$h = 8$）
2. 在每个子空间并行执行注意力计算
3. 拼接所有头的输出并再次线性投影

3.2.2 位置前馈网络（Position-wise Feed-Forward Network） 对每个位置独立应用相同的两层全连接网络：

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

其中：

- 输入/输出维度：$d_{\text{model}} = 512$
- 内部层维度：$d_{ff} = 2048$

3.2.3 残差连接与层归一化 每个子层采用**残差连接**（Residual Connection）：

$$\text{Output} = \text{LayerNorm}(x + \text{Sublayer}(x))$$

这确保了即使网络很深，梯度也能有效流动。

3.3 Decoder 详解

Decoder 同样由 **N = 6 个相同的层**组成，但每层包含**三个子层**：

1. **掩码多头自注意力（Masked Multi-Head Self-Attention）**

- 防止位置 i 关注到其之后的任何位置
- 通过将非法连接的注意力权重设为 $-\infty$ 实现

1. **编码器-解码器注意力（Encoder-Decoder Attention）**

- Query 来自前一个解码器层
- Key 和 Value 来自编码器输出
- 允许解码器每个位置关注输入序列的所有位置

1. **位置前馈网络**

- 与 Encoder 中相同

3.4 注意力机制详解

3.4.1 缩放点积注意力（Scaled Dot-Product Attention） 核心公式：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中：

- $Q \in \mathbb{R}^{n \times d_k}$：查询矩阵
- $K \in \mathbb{R}^{m \times d_k}$：键矩阵
- $V \in \mathbb{R}^{m \times d_v}$：值矩阵

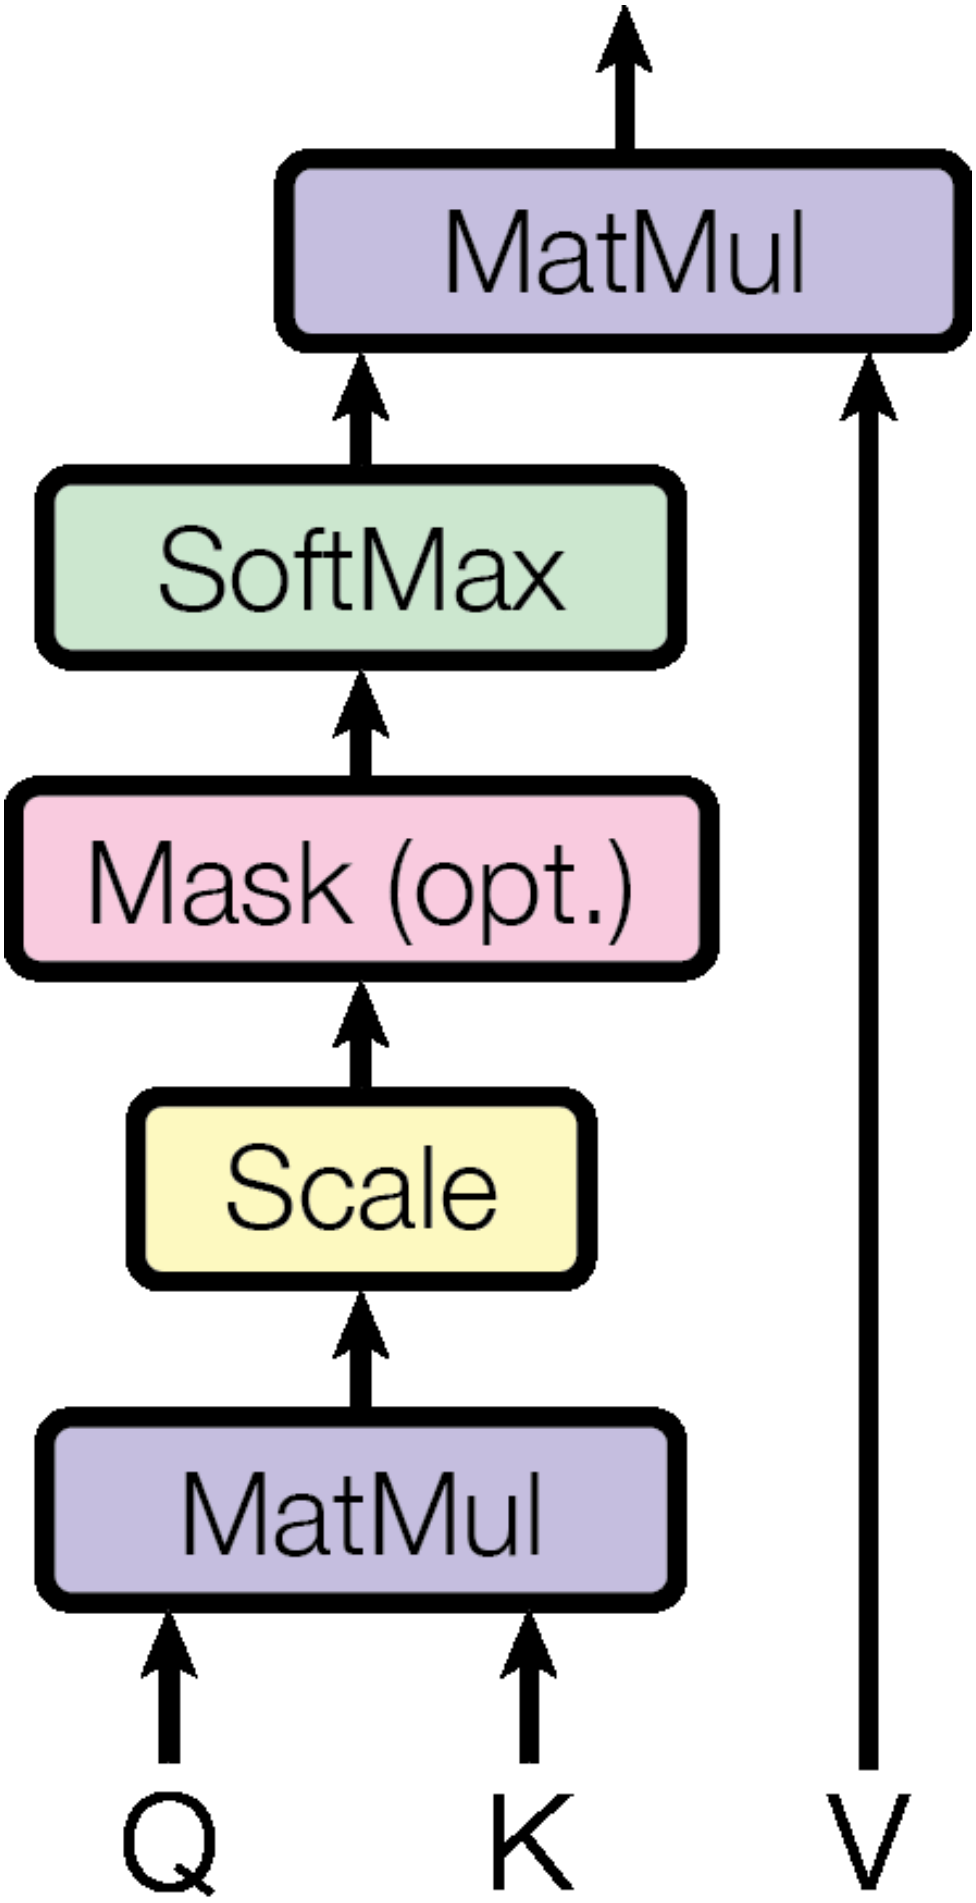
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

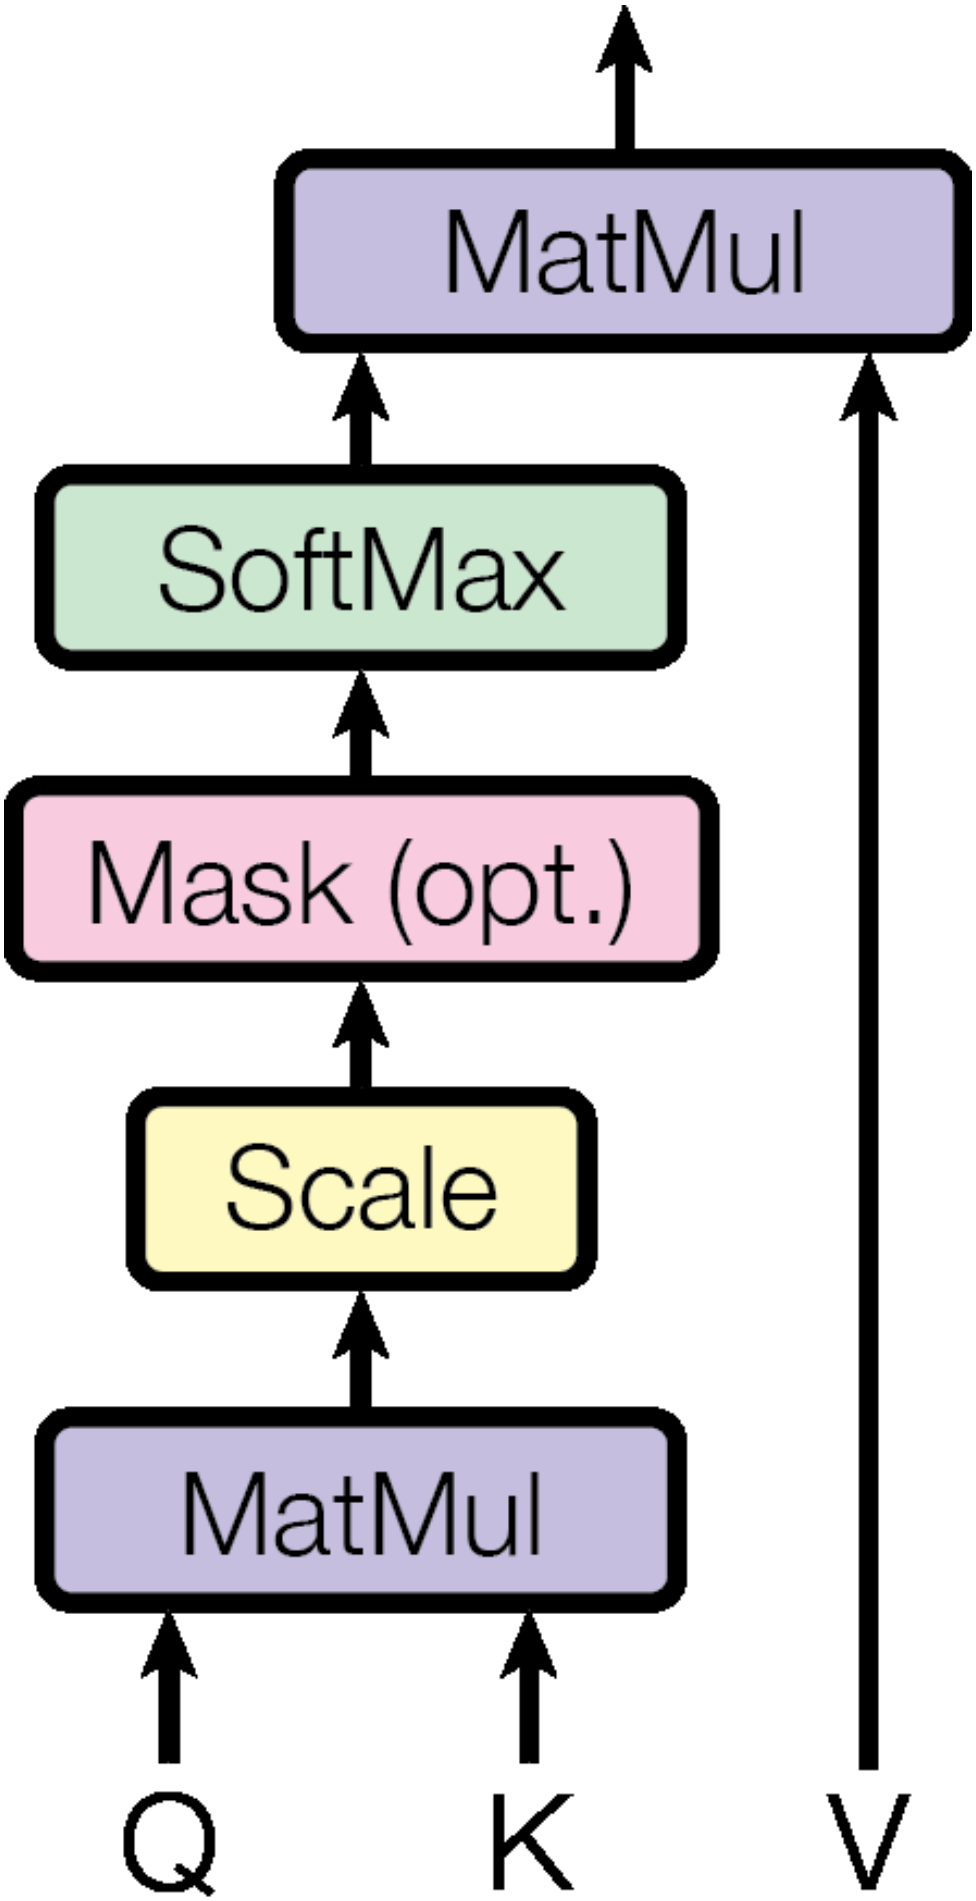
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

- d_k：查询/键的维度

为什么需要缩放?

当 d_k 较大时，点积 $q \cdot k$ 的方差增长到 d_k，导致 softmax 函数进入饱和区，梯度极小。

$$\mathrm{Var}(q \cdot k) = d_k$$

通过除以 $\sqrt{d_k}$，将方差归一化到 1。

3.4.2 多头注意力（Multi-Head Attention） 核心公式:

$$\mathrm{MultiHead}(Q, K, V) = \mathrm{Concat}(\mathrm{head}_1, ..., \mathrm{head}_h)W^O$$

其中:

$$\mathrm{head}_i = \mathrm{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

参数矩阵维度:

- $W_i^Q \in \mathbb{R}^{d_{\mathrm{model}} \times d_k}$
- $W_i^K \in \mathbb{R}^{d_{\mathrm{model}} \times d_k}$
- $W_i^V \in \mathbb{R}^{d_{\mathrm{model}} \times d_v}$
- $W^O \in \mathbb{R}^{hd_v \times d_{\mathrm{model}}}$

本文配置:

- $h = 8$ 个并行注意力头
- $d_k = d_v = d_{\mathrm{model}}/h = 64$
- 总计算量与单头全维度注意力相近

3.5 位置编码（Positional Encoding）

由于 Transformer 不包含循环和卷积，必须**显式注入位置信息**。

3.5.1 正弦/余弦位置编码

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\mathrm{model}}}}\right)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\mathrm{model}}}}\right)$$

其中:

- pos：位置（0, 1, 2, ...）
- i：维度索引（0, 1, 2, ..., $d_{\mathrm{model}}/2$）

设计动机：对于任意固定偏移 k，PE_{pos+k} 可以表示为 PE_{pos} 的**线性函数**，便于模型学习相对位置依赖。

3.5.2 与其他方法的对比 实验表明，学习到的位置嵌入与正弦位置编码效果相近。选择正弦编码是因为它能**外推到比训练时更长的序列**。

3.6 复杂度分析

层类型	每层复杂度	最小顺序操作数	最大路径长度
自注意力	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
循环层	$O(n \cdot d^2)$	$O(n)$	$O(n)$
卷积层	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k(n))$

---

4. 实验设计与结果分析

4.1 数据集与评估指标

任务	数据集	词汇量	句子对数量
英德翻译	WMT 2014	~37,000 BPE tokens	~450 万对
英法翻译	WMT 2014	~32,000 word-piece	~3600 万对

评估指标：BLEU 分数（机器翻译的标准评估指标）

4.2 主实验结果

4.2.1 机器翻译性能

模型	英德 BLEU	英法 BLEU	训练成本 (FLOPs)
ByteNet	23.75	-	-
GNMT + RL	24.6	39.92	2.3×10^{19}
ConvS2S	25.16	40.46	9.6×10^{18}
MoE	26.03	40.56	2.0×10^{19}
Transformer (base)	**27.3**	**38.1**	3.3×10^{18}
Transformer (big)	**28.4**	**41.8**	2.3×10^{19}

关键发现：

- **Transformer (big)** 在英德翻译上比之前最优模型**提升超过 2 BLEU**
- 训练成本仅为最佳模型的**一小部分**
- 仅用 **3.5 天在 8 块 P100 GPU** 上完成训练

4.2.2 注意力可视化 论文提供了注意力权重的可视化分析，揭示了模型学习到的重要语言现象：

1. **长距离依赖捕捉**：编码器第 5 层的注意力头能够关注到远距离的相关词（如"making"与"more difficult"）

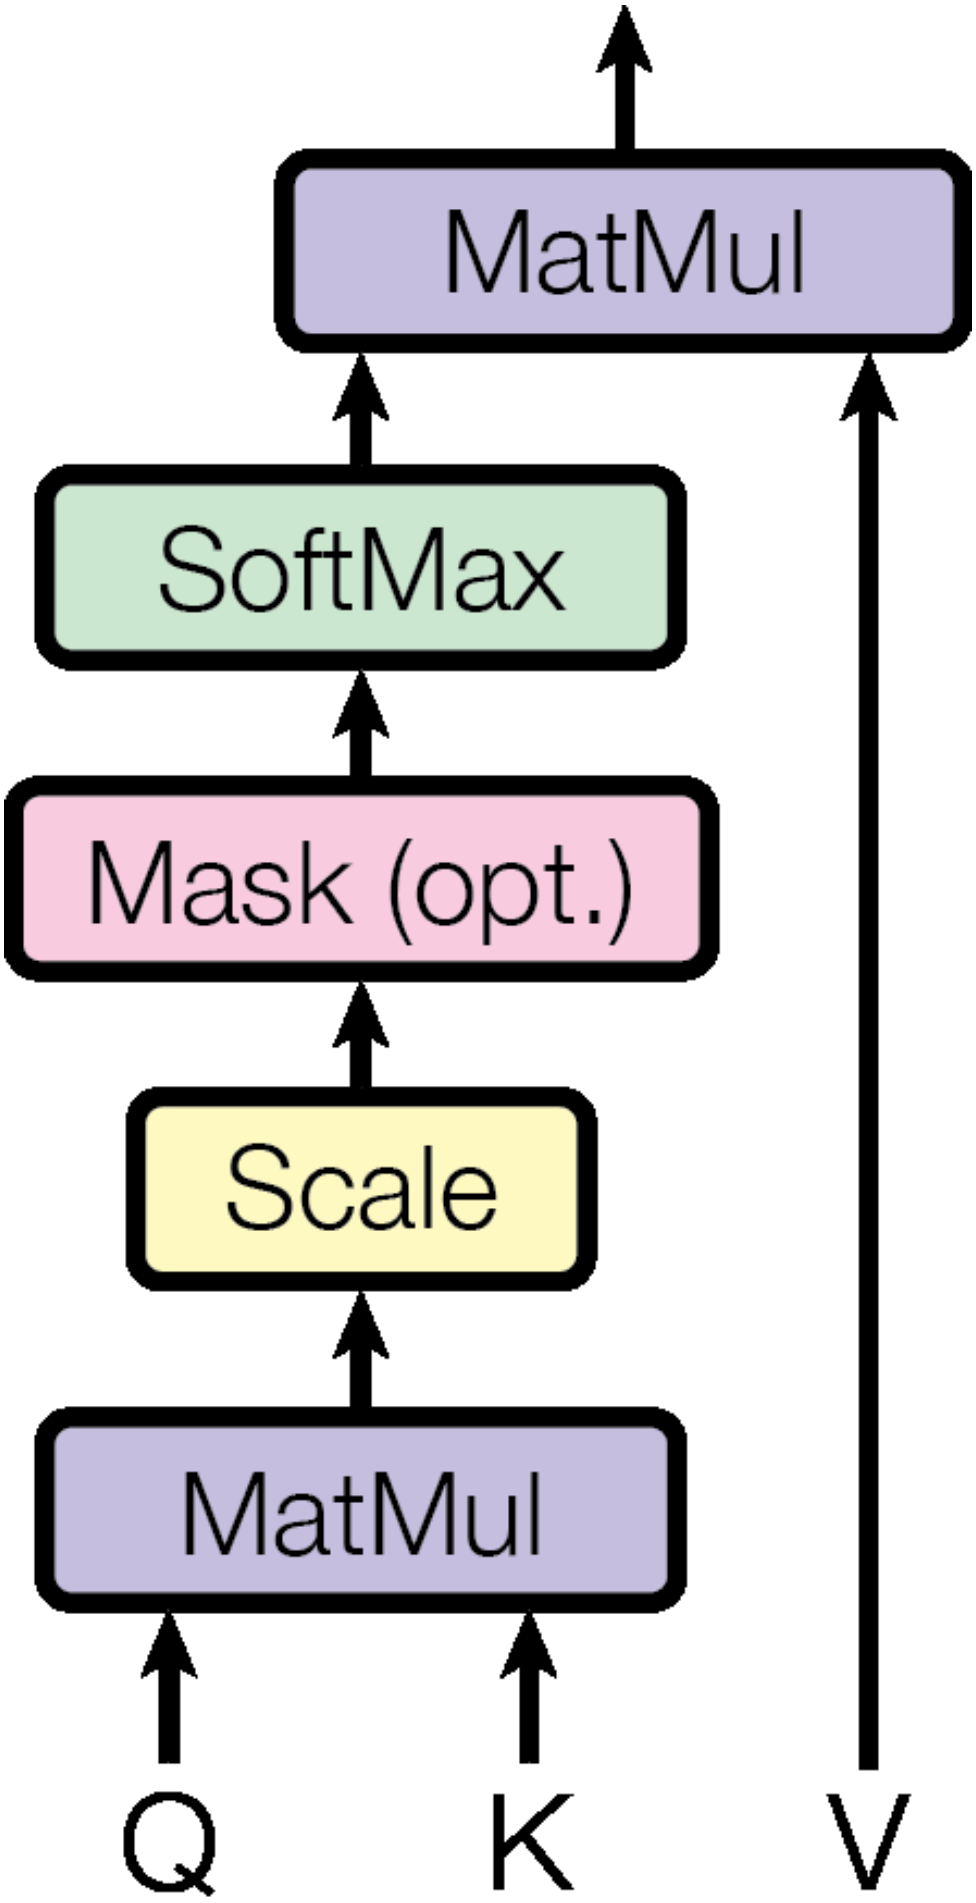
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

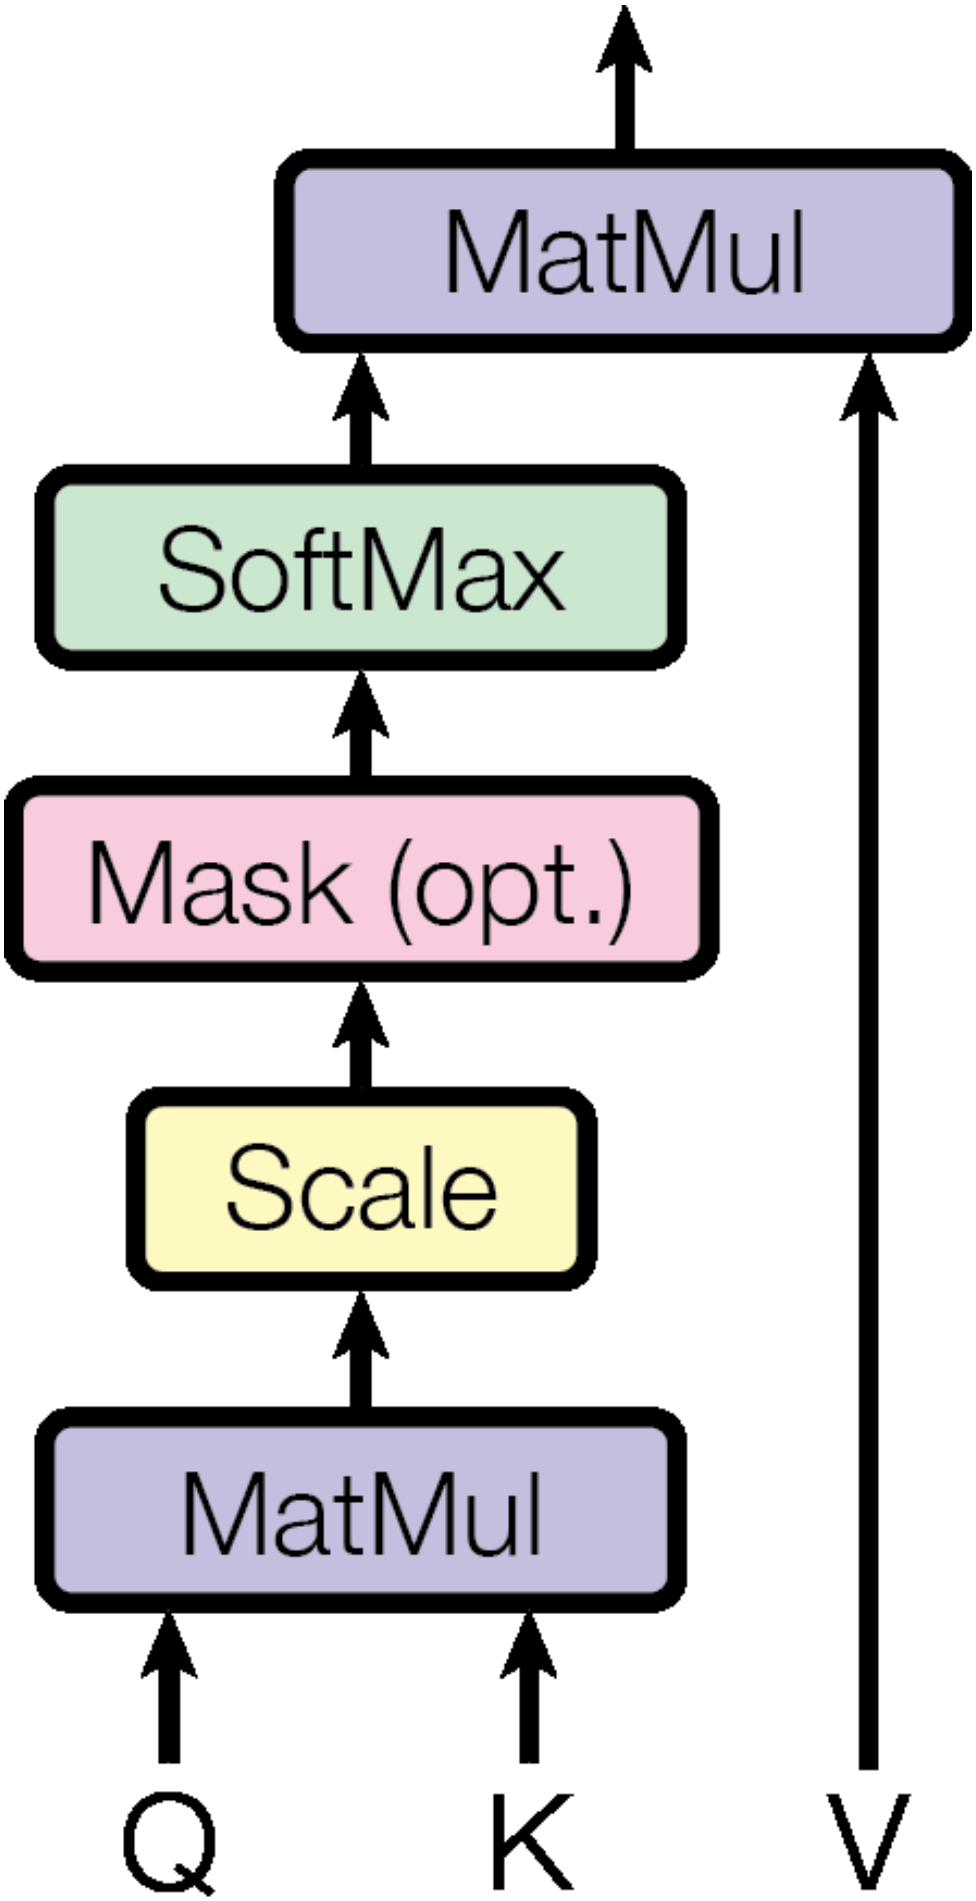
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

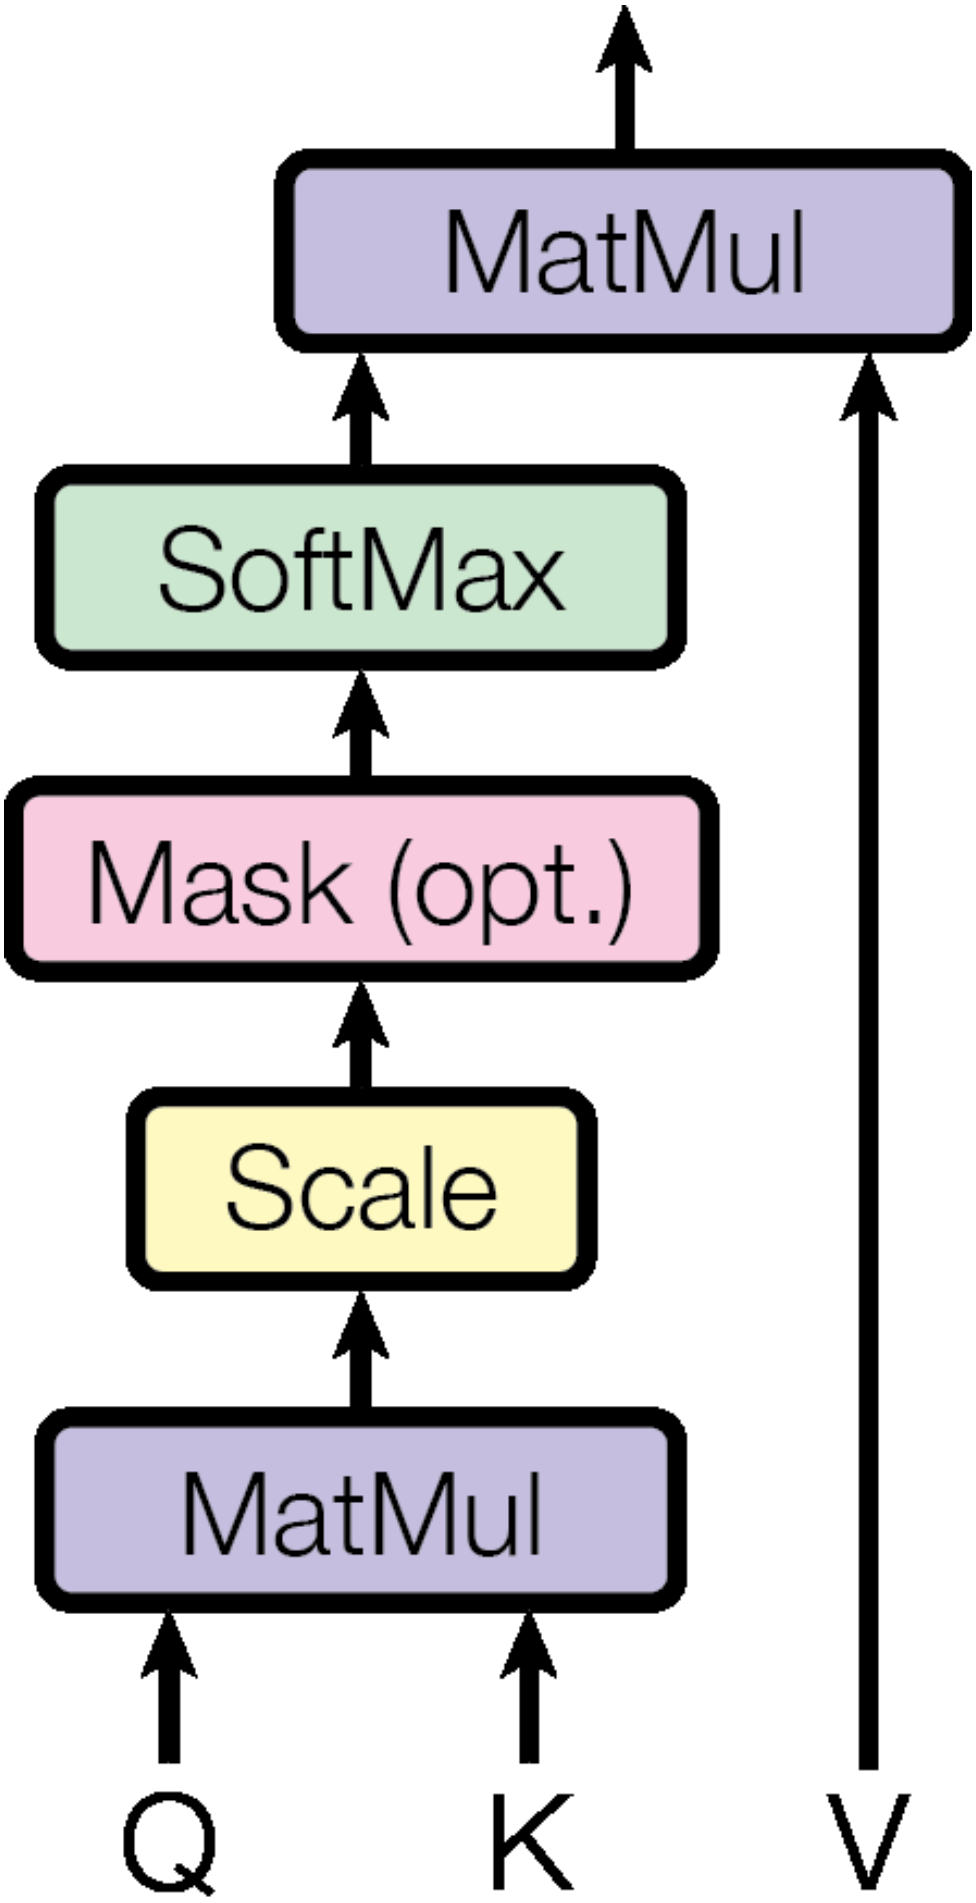
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

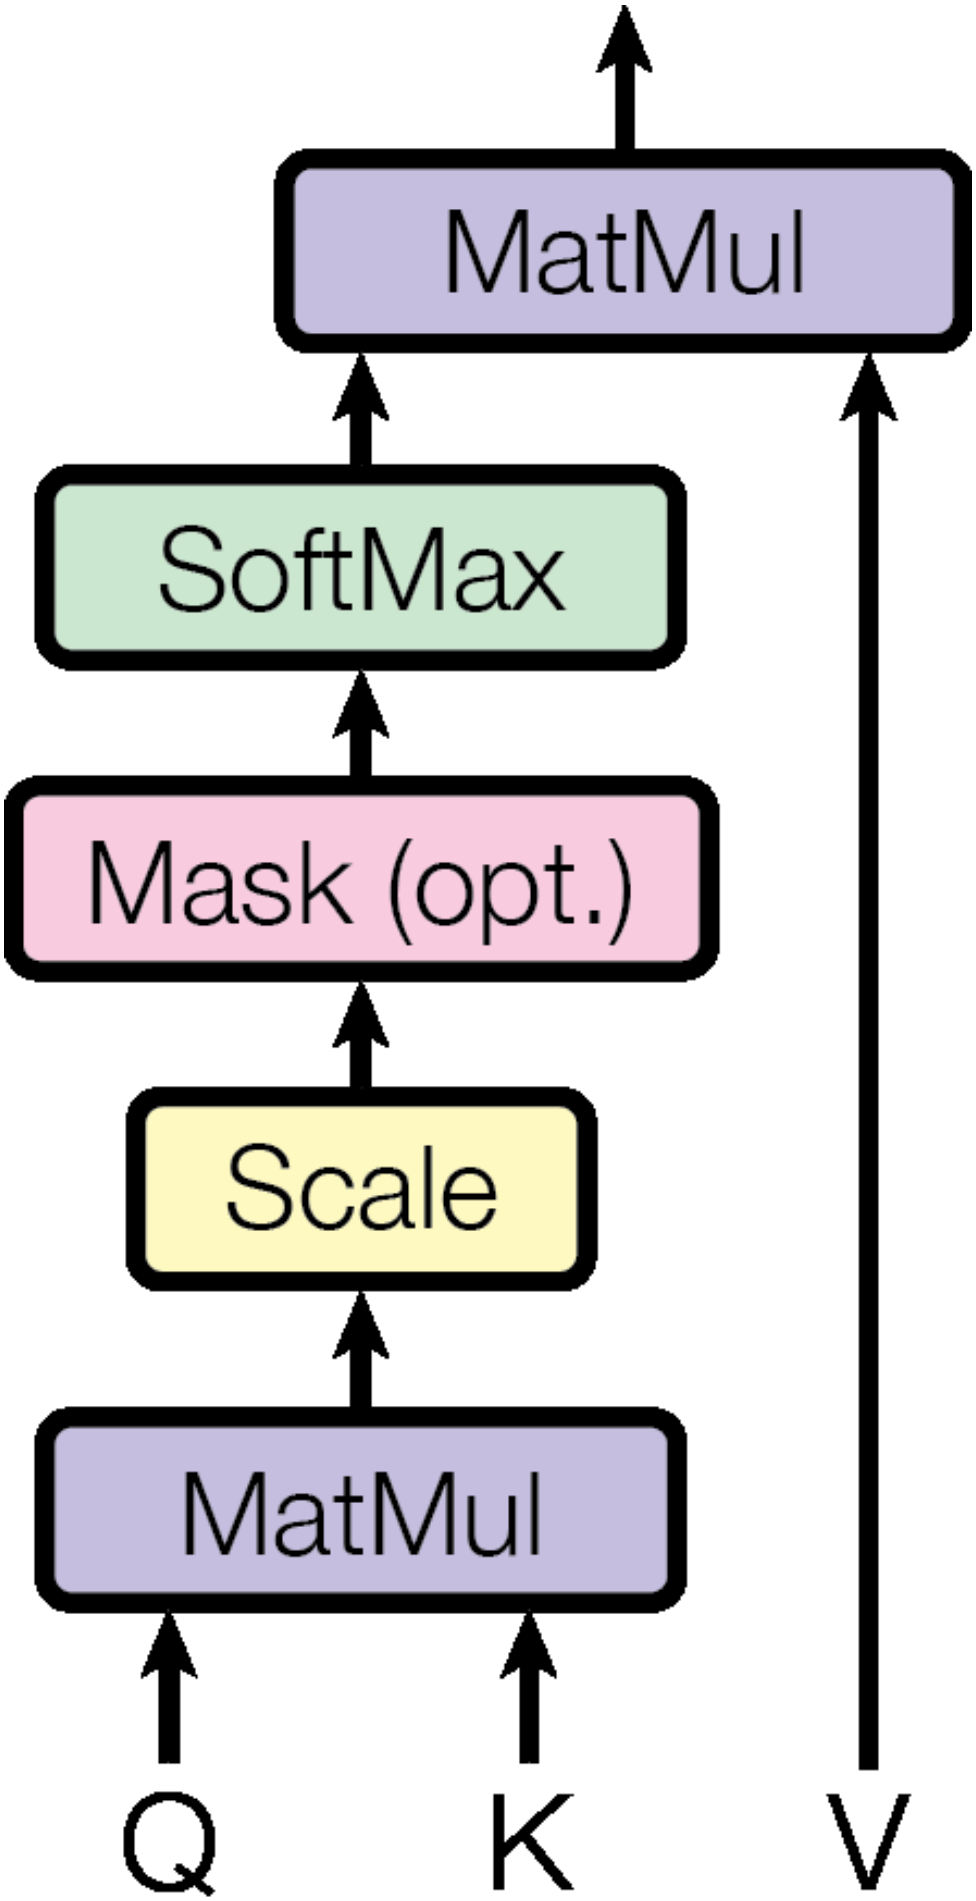
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

1. **指代消解**：某些注意力头专门负责处理代词与其指代对象的对应关系

1. **句法结构学习**：不同注意力头学习到与句子结构相关的模式

4.3 消融实验分析

实验配置	BLEU (dev)	PPL
Base Model	25.8	4.92
(A) 单头注意力	24.9	5.29
(A) 16 头, dk=dv=32	25.4	5.01
(B) dk=16	25.1	5.16
(C) 4 层	23.7	6.11
(C) 8 层	25.5	4.88
(D) 无 Dropout	24.6	5.77
(E) 学习位置编码	25.7	4.92
Big Model	26.4	4.33

消融实验关键发现：

1. **注意力头数量**：8 头效果最佳，过多或过少都会导致性能下降

2. **键维度 dk**：较小的 dk（如 16）会损害模型性能

3. **模型深度**：6 层是性能和计算成本的良好平衡

4. **Dropout**：正则化对防止过拟合至关重要

5. **位置编码**：正弦编码与学习编码效果相近

4.4 泛化能力验证：句法分析

模型	训练设置	WSJ F1
Vinyals & Kaiser et al.	WSJ only	88.3
Dyer et al. (RNNG)	WSJ only	91.7
Transformer (4 层)	WSJ only	**91.3**
Dyer et al. (RNNG)	半监督	93.3
Transformer (4 层)	半监督	**92.7**

关键发现：Transformer 在**无任务特定调优**的情况下，在 constituency parsing 任务上取得竞争力结果，证明其强大的泛化能力。

5. 优缺点评价

5.1 主要优点

1. **高度并行化**：完全消除顺序依赖，训练速度大幅提升
2. **路径长度常数化**：$O(1)$ 的最大路径长度使其能有效捕捉长距离依赖
3. **可解释性增强**：注意力权重提供了模型决策的直观可视化
4. **泛化能力强**：在完全不同的任务（翻译 → 句法分析）上表现优异
5. **计算效率高**：在保持/提升性能的同时显著降低训练成本

5.2 主要局限性

1. **二次方复杂度**：自注意力的 $O(n^2)$ 复杂度使其难以处理极长序列
2. **位置编码的局限**：虽然正弦编码支持外推，但对绝对位置的表示可能不够灵活
3. **归纳偏置缺失**：相比 CNN 和 RNN，Transformer 对序列结构的假设更少，可能需要更多数据来学习

5.3 可能的改进方向

1. **高效注意力机制**：Sparse Attention、Linear Attention、FlashAttention 等
2. **增强位置编码**：相对位置编码、可学习的位置表示
3. **模型扩展**：更宽的模型、更深的层数、混合专家架构
4. **多模态扩展**：将 Transformer 应用于图像、音频、视频等其他模态

---

6. 个人思考与启发

6.1 对研究的启发

1. **注意力优先的设计理念**：Transformer 证明了注意力机制可以作为序列建模的**唯一基础**，而非辅助工具。这一思想深刻影响了后续预训练语言模型的设计。

1. **简单性与效率的平衡**：通过移除复杂的循环和卷积结构，Transformer 以更简洁的架构实现了更好的性能。这提醒我们在模型设计中追求**优雅和高效**。

1. **缩放的重要性**：这篇论文开启了大型语言模型（LLM）时代的序幕，展示了模型规模与性能之间的 scaling law。

6.2 可借鉴的思想和技术

1. **多头注意力的设计**：将注意力分散到多个子空间，增强了模型捕捉多样化依赖的能力
2. **残差连接与层归一化**：这些技术的组合成为现代深度学习模型的标配
3. **学习率调度**：warmup + inverse square root decay 策略被广泛采用
4. **Label Smoothing**：提升泛化能力的简单技巧

6.3 可能的 Follow-up 研究方向

1. **高效 Transformer**：解决 $O(n^2)$ 复杂度问题，支持更长序列
2. **轻量化 Transformer**：知识蒸馏、量化、剪枝等技术
3. **Transformer 的理论分析**：理解其表达能力、泛化性质
4. **跨模态 Transformer**：视觉 Transformer（ViT）、多模态大模型

---

7. 关键词与核心概念

术语	解释
Transformer	完全基于注意力机制的序列到序列模型架构
Self-Attention	自注意力，允许序列内任意位置相互 attend 的机制
Multi-Head Attention	多头注意力，并行执行多个注意力函数，增强表示能力
Scaled Dot-Product Attention	缩放点积注意力，通过除以 $\sqrt{d_k}$ 防止梯度消失
Encoder-Decoder	编码器-解码器结构，先编码输入序列，再解码生成输出
Positional Encoding	位置编码，为无位置信息的注意力机制注入序列位置信息
Residual Connection	残差连接，缓解深层网络训练困难的经典技术
Layer Normalization	层归一化，稳定训练过程的归一化技术
BLEU	Bilingual Evaluation Understudy，机器翻译的标准评估指标
Sequence Transduction	序列转导，将一个序列转换为另一个序列的任务
Feed-Forward Network	前馈神经网络，Transformer 中每个位置独立应用的全连接网络
Auto-regressive	自回归，生成时依赖先前生成的符号
Masked Attention	掩码注意力，防止看到未来信息的注意力机制
Label Smoothing	标签平滑，用软标签替代硬标签的正则化技术

附录：核心公式汇总

缩放点积注意力：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

多头注意力：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, ..., \text{head}_h)W^O$$

前馈网络：

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

学习率调度：

$$lrate = d_{\text{model}}^{-0.5} \cdot \min(step_num^{-0.5}, step_num \cdot warmup_steps^{-1.5})$$

残差连接：

$$\text{Output} = \text{LayerNorm}(x + \text{Sublayer}(x))$$